基于近端梯度法的 Lasso 稀疏回归求解与数值实验

最优化方法课程研究报告

2026 年 10 月 31 日

摘要

针对高维线性回归中参数数目超过样本数、且真实参数具有稀疏性的情形，本文研究带 ℓ_1 正则化的 Lasso 模型。通过分离光滑损失项与非光滑正则项，推导软阈值近端算子，独立实现近端梯度法 ISTA，并以标准 FISTA 作为加速对照。采用 $p = 1000$、真实稀疏度 $s = 20$ 的高斯随机回归问题，在 5 个固定随机种子下开展算法收敛、步长、正则化强度及数据难度实验。两种方法均以归一化 KKT 残差和原始–对偶间隙同时不超过 10^{-6} 为停止条件，并与高精度坐标下降结果交叉验证。在独立特征和相关系数 $\rho = 0.8$ 的算法基准中，FISTA 相对 ISTA 的平均迭代数比值分别对应约 1.10 倍和 1.44 倍的加速。基础场景经验证集选参后，测试均方误差为 0.348 ± 0.057，参数相对误差为 0.0738 ± 0.0124；平均选择 77.0 个变量，说明预测效果与精确支持集恢复并不等价。全部报告数值来自配套程序的实际运行，提供原始 CSV、迭代轨迹、图表和复现脚本。

关键词： Lasso；近端梯度法；ISTA；FISTA；稀疏回归；数值优化

1 研究背景与研究问题

在传感器测量、信号重建或包含大量候选因素的回归建模中，常会遇到变量数多于观测数的情况。若仅最小化训练残差，可能存在多个拟合良好的参数向量；训练误差很小也不代表对新数据预测准确。当先验认为只有少数变量真正起作用时，可以在拟合误差之外增加稀疏性约束。Lasso 通过对参数的绝对值之和施加惩罚，同时完成回归和变量筛选 [1]。

本文采用任务允许的**随机生成问题**，而非声称使用某个真实业务数据集。这样可以同时知道真实参数和噪声水平，在可控条件下检验算法与模型。研究围绕三个问题展开：第一，如何将 Lasso 的非光滑优化转化为易于实现的迭代；第二，ISTA 与 FISTA 在相同精度下的计算表现如何；第三，步长、正则化强度、样本量、噪声和相关性如何影响结果。这里区分**优化误差**与**统计误差**：前者衡量离 Lasso 最优值还有多远，后者衡量估计参数或预测结果离真实机制有多远。

2 数学模型与最优性条件

2.1 Lasso 模型

设 $A \in \mathbb{R}^{n\times p}$ 为经过训练集标准化的特征矩阵，$b \in \mathbb{R}^n$ 为中心化后的响应，研究

$$\min_{x\in\mathbb{R}^p} F(x) = f(x) + g(x) = \frac{1}{2n}\|Ax - b\|_2^2 + \lambda\|x\|_1, \qquad \lambda > 0. \tag{1}$$

其中 f 衡量拟合误差，g 鼓励稀疏。F 是连续凸函数，且 $\lambda\|x\|_1$ 保证其水平集有界，因此存在最优解。由于 $p > n$ 时 $A^\top A$ 不满秩，不能仅凭这一模型宣称全局强凸、参数解必然唯一或全局线性收敛。本文比较目标值和最优性证书，不将求解器参数完全相等作为一般性的正确性要求。

光滑部分满足

$$\nabla f(x) = \frac{1}{n} A^\top (Ax - b), \qquad \nabla^2 f(x) = \frac{1}{n} A^\top A, \qquad L = \frac{\|A\|_2^2}{n}. \tag{2}$$

L 是梯度的 Lipschitz 常数。这里矩阵 2 范数为最大奇异值，**不是 Frobenius 范数**。

2.2 KKT 条件与零解阈值

令 $q = \nabla f(x)$。由凸问题的一阶最优性条件，x 最优当且仅当

$$0 \in q + \lambda \partial \|x\|_1, \quad \text{即} \quad \begin{cases} q_j + \lambda \operatorname{sign}(x_j) = 0, & x_j \neq 0, \\ |q_j| \leq \lambda, & x_j = 0. \end{cases} \tag{3}$$

代入 $x = 0$，可知当 $\lambda \geq \lambda_{\max}$ 时，零向量是一个最优解，其中

$$\lambda_{\max} = \frac{\|A^\top b\|_\infty}{n}. \tag{4}$$

因此用 $\lambda/\lambda_{\max}$ 描述正则化强度，比直接给出一组与数据尺度无关的绝对数值更清楚。

3 近端梯度法的推导与实现

3.1 从二次上界到近端更新

因为 ℓ_1 范数在零点不可微，普通光滑梯度下降公式不能直接用于整个 F。在当前点 x^k 线性化 f，并加入二次稳定项，得到

$$x^{k+1} = \arg\min_z \left\{ f(x^k) + \langle \nabla f(x^k), z - x^k \rangle + \frac{1}{2\eta} \left\| z - x^k \right\|_2^2 + g(z) \right\}. \tag{5}$$

配方并去掉与 z 无关的项，记 $v = x^k - \eta \nabla f(x^k)$，则

$$x^{k+1} = \operatorname{prox}_{\eta g}(v) = \arg\min_z \left\{ \frac{1}{2} \|z - v\|_2^2 + \eta\lambda \|z\|_1 \right\}. \tag{6}$$

该问题按坐标分离。对标量问题 $\min_u \frac{1}{2}(u - v_j)^2 + \tau|u|$，分别考察 $u > 0$、$u < 0$、$u = 0$：前两种情形的一阶条件给出 $u = v_j - \tau$ 和 $u = v_j + \tau$；第三种情形要求 $v_j \in [-\tau, \tau]$。于是得到软阈值算子

$$\mathcal{S}_\tau(v_j) = \begin{cases} v_j - \tau, & v_j > \tau, \\ 0, & |v_j| \leq \tau, \\ v_j + \tau, & v_j < -\tau, \end{cases} = \operatorname{sign}(v_j) \max\{|v_j| - \tau, 0\}. \tag{7}$$

最终，Lasso 的近端梯度迭代为

$$\boxed{x^{k+1} = \mathcal{S}_{\eta\lambda}\left(x^k - \frac{\eta}{n} A^\top (Ax^k - b) \right).} \tag{8}$$

阈值必须是 $\eta\lambda$，且梯度中的 $1/n$ 必须与目标函数的定义保持一致。每次更新将较小分量置零，并将较大分量向零收缩，这同时解释了稀疏性和参数收缩偏差。迭代阈值方法在稀疏逆问题中的研究可参见文献 [2]。

3.2 步长、下降性质与收敛率

取 $0 < \eta \le 1/L$ 时，式(5)中的函数是 F 的上界，且在 x^k 处取等号。记此上界为 $Q_\eta(z; x^k)$，则

$$F(x^{k+1}) \le Q_\eta(x^{k+1}; x^k) \le Q_\eta(x^k; x^k) = F(x^k). \tag{9}$$

因此 ISTA 的目标函数值单调不增。对任意最优解 $x^\star$，近端最优性还给出

$$F(x^{k+1}) - F(x^\star) \le \frac{\|x^k - x^\star\|_2^2 - \|x^{k+1} - x^\star\|_2^2}{2\eta}. \tag{10}$$

将其求和，并结合目标值的单调性，可得

$$F(x^k) - F(x^\star) \le \frac{\|x^0 - x^\star\|_2^2}{2\eta k}. \tag{11}$$

特别地，$\eta = 1/L$ 时为 $O(1/k)$ 的最坏情形目标误差界 [3]。这一上界不意味着每个实例的实测曲线都严格按 $1/k$ 衰减，也不直接给出参数恢复误差的速率。

3.3 FISTA 加速对照

为考察动量的影响，加入未使用重启策略的标准 FISTA。设 $x^0 = y^0 = 0$、$t_0 = 1$，依次计算

$$x^{k+1} = \mathcal{S}_{\lambda/L}\left(y^k - \frac{1}{L}\nabla f(y^k)\right), \tag{12}$$

$$t_{k+1} = \frac{1 + \sqrt{1 + 4t_k^2}}{2}, \tag{13}$$

$$y^{k+1} = x^{k+1} + \frac{t_k - 1}{t_{k+1}}(x^{k+1} - x^k). \tag{14}$$

在同样的凸性和 Lipschitz 梯度条件下，FISTA 满足 [3]

$$F(x^k) - F(x^\star) \le \frac{2L\|x^0 - x^\star\|_2^2}{(k+1)^2}. \tag{15}$$

其目标值不保证逐步单调。理论比较针对目标误差的最坏情形上界，并不保证在每个实例、每个精度或以 KKT 残差作为停止条件时，FISTA 都比 ISTA 快。

对本研究的二次损失，梯度是仿射函数，故对任意动量系数 a 有

$$\nabla f\big(x^k + a(x^k - x^{k-1})\big) = \nabla f(x^k) + a\big(\nabla f(x^k) - \nabla f(x^{k-1})\big). \tag{16}$$

实现据此复用梯度，使两种方法每轮均只需一次 A 和一次 $A^\top$ 的矩阵–向量乘法，同时得到新点的最优性证书。密集矩阵下每轮代价为 $O(np)$，除矩阵外的工作存储为 $O(n+p)$。

3.4 停止条件与数值证书

仅观察目标函数变化小可能过早停止。本文同时要求**归一化 KKT 残差**和**归一化原始–对偶间隙**均不大于 10^{-6}。定义

$$v_j(x) = \begin{cases} |q_j + \lambda\,\mathrm{sign}(x_j)|, & x_j \ne 0, \\ (|q_j| - \lambda)_+, & x_j = 0, \end{cases} \qquad R_{\mathrm{KKT}}(x) = \frac{\|v(x)\|_\infty}{\max\{1, \lambda_{\max}\}}. \tag{17}$$

KKT 计算使用算法给出的精确零分量；统计支持集时另用 10^{-5} 阈值，两者用途不同。

为得到可计算的目标误差上界，令 $e = b - Ax$，由约束表示 $e = b - Ax$ 的拉格朗日函数消去 e, x，可得对偶问题

$$\max_{\theta} D(\theta) = b^{\top}\theta - \frac{n}{2}\|\theta\|_2^2, \qquad \left\|A^{\top}\theta\right\|_{\infty} \le \lambda. \tag{18}$$

用残差构造可行点

$$\theta = \frac{e}{nc}, \qquad c = \max\left\{1, \frac{\|A^{\top}e\|_{\infty}}{n\lambda}\right\}. \tag{19}$$

由弱对偶性，$0 \le F(x) - F(x^{\star}) \le F(x) - D(\theta)$。因此使用

$$G_{\text{rel}}(x) = \frac{F(x) - D(\theta)}{\max\{1, |F(x)|\}}, \qquad \max\{R_{\text{KKT}}(x), G_{\text{rel}}(x)\} \le 10^{-6} \tag{20}$$

作为共同停止准则。程序只把浮点舍入量级的负间隙截为零，显著负值会触发错误。另设 50000 次迭代上限；未达到准则的结果不会被标记为收敛。

4 实验设计与可复现设置

4.1 数据生成、预处理与划分

在原始坐标下生成

$$Z_{i,:} \sim \mathcal{N}(0, \Sigma), \qquad \Sigma_{jk} = \rho^{|j-k|}, \qquad y = Z\beta_{\text{true}} + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2 I). \tag{21}$$

从 $p = 1000$ 个坐标中均匀无放回选取 $s = 20$ 个，非零系数的符号等概率取正负，绝对值服从 Uniform$(0.5, 1.5)$。设

$$\sigma = \delta\sqrt{\beta_{\text{true}}^{\top}\Sigma\beta_{\text{true}}}, \qquad \text{SNR}_{\text{dB}} = -20\log_{10}\delta. \tag{22}$$

基础场景取 $n = 300$、$\rho = 0$、$\delta = 0.1$，即总体信噪比为 20 dB。验证集和测试集分别有 300、1000 个独立样本。三组数据共享真实参数，使用独立随机子流。

仅由训练集计算每列均值 μ_j、标准差 s_j（分母为 n）和响应均值 $\bar{y}$，令 $A_{ij} = (Z_{ij} - \mu_j)/s_j$、$b_i = y_i - \bar{y}$。验证集和测试集均沿用这些训练统计量。求得 $\hat{x}$ 后，原始尺度参数为 $\hat{\beta}_j = \hat{x}_j/s_j$，预测值为

$$\hat{y}(z) = (z - \mu)^{\top}\hat{\beta} + \bar{y}. \tag{23}$$

因此截距没有受到 ℓ_1 惩罚，也没有用验证或测试数据重新估计标准化参数。

固定随机种子为 20261031、20261101、20261102、20261103、20261104。同一随机种子在各难度条件下复用真实参数和对应随机子流，以减少无关随机差异。表中的“均值 ± 标准差”均为这 5 次独立种子实验的样本标准差（分母为 4），并非置信区间。

4.2 实验分组与参数选择

三个难度实验共享基础场景，合计 7 个不同场景、35 个数据集。每个数据集先使用 FISTA 求解 7 个候选正则化参数，共 245 次候选拟合，再按**验证集 MSE 最小**选定一个模型，并用 ISTA 重新求解该参数，以验证主体方法同样达到要求。测试集仅用于最终评价和展示预先指定网格的响应曲线，**不参与选择** λ。选参后不合并训练集与验证集重新拟合，以保持各表使用同一问题定义。

表 1 实验设置；未说明的参数均取基础场景数值

实验	设置及目的
算法比较	$\rho \in \{0, 0.8\}$，固定 $\lambda = 0.05\lambda_{\max}$；两算法从零初始化、同精度停止。
步长实验	ISTA 使用 $\eta \in \{0.25/L, 0.5/L, 1/L\}$，固定 $\lambda = 0.05\lambda_{\max}$。
正则化实验	$\lambda/\lambda_{\max} \in \{0.001, 0.003, 0.01, 0.03, 0.1, 0.3, 1\}$；每个候选均从零初始化。
样本量实验	$n \in \{150, 300, 600\}$，其余条件固定。
噪声实验	$\delta \in \{0.05, 0.1, 0.3\}$，其余条件固定。
相关性实验	$\rho \in \{0, 0.5, 0.9\}$，其余条件固定。

4.3 指标、参照解与计时口径

除式(20)中的优化指标外，记录原始尺度参数相对误差 $\left\|\hat{\beta} - \beta_{\text{true}}\right\|_2 / \|\beta_{\text{true}}\|_2$、测试 MSE、非零参数数目，以及支持集精确率、召回率、F1。估计支持集定义为 $|\hat{\beta}_j| > 10^{-5}$。记真阳性、假阳性和假阴性分别为 TP、FP、FN，则精确率为 $\text{TP}/(\text{TP}+\text{FP})$，召回率为 $\text{TP}/(\text{TP}+\text{FN})$，F1 为二者的调和平均；空预测支持集的精确率和 F1 记为零。

参照解使用 scikit-learn 1.6.1 的坐标下降实现，设置 `alpha=lambda`、`fit_intercept=False`、`tol=1e-12`，使其目标函数与式(1)完全一致 [4]。参照解也独立检查 KKT 和对偶间隙；其数值目标记为 F_{ref}，不将其当作解析最优值。共检查 10 个算法基准问题和 35 个验证集选定问题。

实验运行于 Apple M4，Python 3.13.12，NumPy 2.2.6，SciPy 1.15.3，使用 OpenBLAS，线程数限定为 1。每个算法基准先预热，每个数据集的每种方法重复计时 3 次取中位数，再对 5 个种子汇总；循环交替算法执行顺序。计时包含初始梯度、迭代和每轮证书检查，不含数据生成、谱常数计算、参照解和图表生成。谱常数通过较小 Gram 矩阵的最大特征值获得，并乘 $1 + 10^{-12}$ 防止舍入导致步长略大；基础场景这项一次性开销平均为 5.04 ms，单独存入原始数据。图中带轨迹的求解另行运行，不使用其时间制作基准计时表。

5 实验结果与讨论

5.1 正确性和算法收敛

6 项数值测试全部通过，覆盖非均匀对角设计的解析解、$\lambda_{\max}$ 零解、独立坐标下降对照、任意迭代点的对偶可行性、训练集预处理隔离，以及谱常数和零设计矩阵的边界情形。全部 245 次候选拟合、35 次选定参数的 ISTA 复核和算法基准求解均达到共同停止准则。与高精度参照解相比，所核验的 ISTA/FISTA 目标函数绝对差最大为 3.90×10^{-12}；参照解的归一化 KKT 和间隙的最大值为 2.29×10^{-11}。

表 2 固定正则化强度下的算法比较（5 个种子）

ρ	方法	迭代次数	时间 / ms	最大 R_{KKT}	最大 G_{rel}
0	ISTA	305.6 ± 51.1	27.01 ± 4.62	9.37×10^{-8}	9.99×10^{-7}
0	FISTA	278.8 ± 28.5	25.35 ± 2.62	7.46×10^{-8}	9.54×10^{-7}
0.8	ISTA	2053.8 ± 465.5	177.76 ± 39.90	1.35×10^{-7}	9.98×10^{-7}
0.8	FISTA	1423.6 ± 260.3	128.09 ± 22.98	7.28×10^{-8}	9.95×10^{-7}

表2显示，独立特征下两种方法都能较快求解；相关特征使迭代次数明显增加。以组内平均迭

代数计算，FISTA 的迭代加速比分别为 1.10 和 1.44；以组内平均时间计算，加速比分别为 1.07 和 1.39。这些数值只描述本次硬件、问题规模、实现和停止精度；不能据此宣称 FISTA 在所有问题上具有固定倍数的加速。

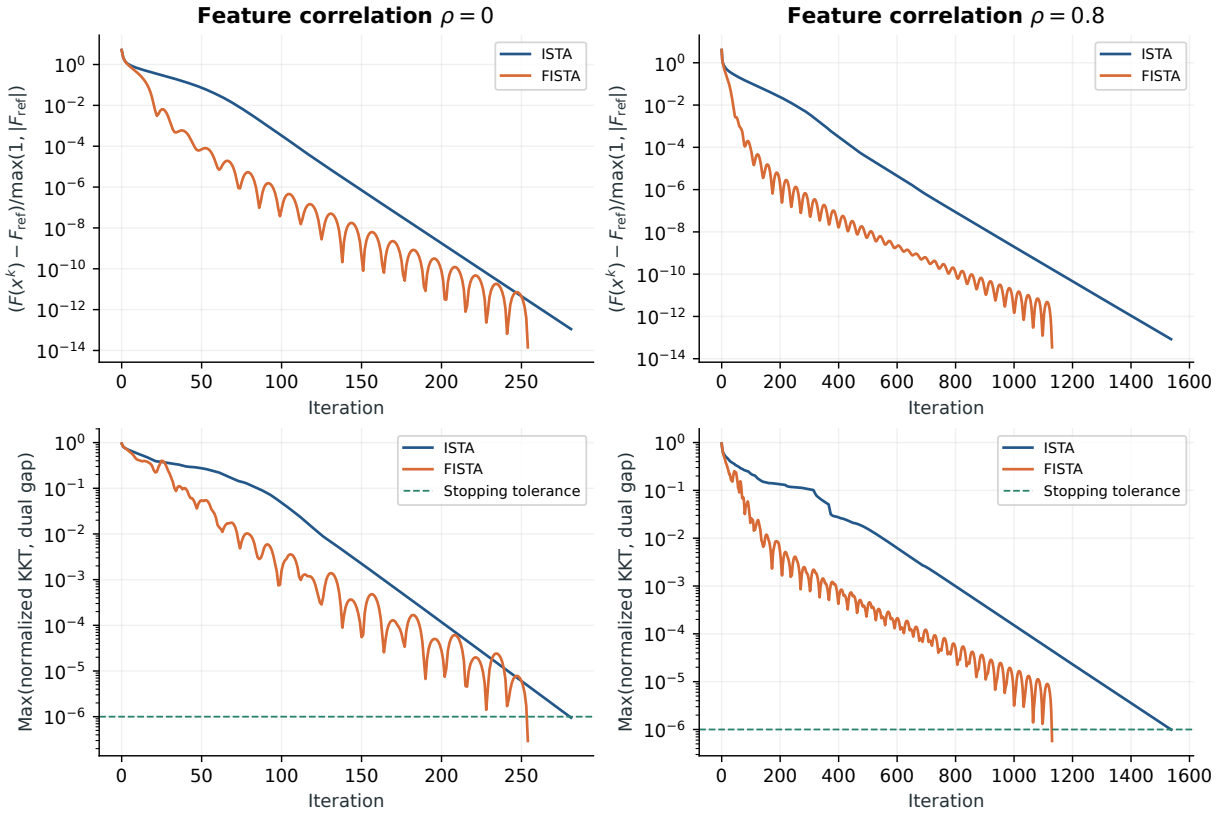


图 1 种子 20261031 的收敛轨迹，上排为相对参照目标差，下排为共同停止指标。目标差仅为对数作图在 10^{-14} 处截断；真实终止依据为下排指标。FISTA 的非单调波动符合其标准形式的特点。

FISTA 在前期迅速降低目标值，但后期仍需要消除动量振荡并满足最优性条件。因此图1中的早期优势与最终迭代数之比不必相同。本实验没有通过拟合一段曲线去“证明”理论阶数，理论速率的依据是式(11)和式(15)的上界。

5.2 步长对 ISTA 的影响

表 3 ISTA 步长实验（5 个种子）

步长	迭代次数	最大 R_{KKT}	最大 G_{rel}
$0.25/L$	1240.8 ± 203.8	9.54×10^{-8}	9.97×10^{-7}
$0.5/L$	617.4 ± 101.9	9.49×10^{-8}	9.96×10^{-7}
$1/L$	305.6 ± 51.1	9.37×10^{-8}	9.99×10^{-7}

在本组固定步长实验中，从 $0.25/L$ 增加到 $1/L$ 后，平均迭代次数由 1240.8 降至 305.6。较小步长虽然仍满足收敛条件，但每步移动有限，累计计算量更大。这支持在已知可靠 L 时使用 $1/L$；并不表示可以无限增大步长。本文未测试超出保证范围的步长，也未比较回溯线搜索。

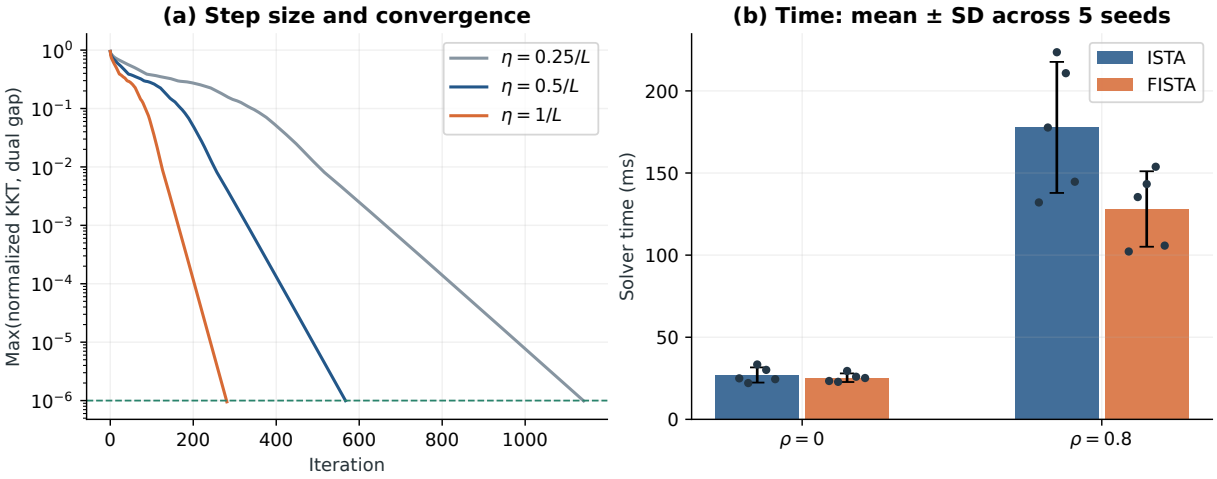


图 2 左：同一实例下 ISTA 的步长影响。右：算法时间均值与标准差；散点表示每个种子的三次计时中位数。

5.3 稀疏恢复与预测效果

基础场景的 5 个种子均由验证集选出 $\lambda = 0.03\lambda_{\max}$。该组测试 MSE 为 0.348 ± 0.057，参数相对误差为 0.0738 ± 0.0124，平均支持集精确率为 0.274、召回率为 1.000。平均噪声方差为 0.2208，逐种子计算的测试 MSE 与噪声方差之比平均为 1.57。噪声方差是知道真实条件均值时的总体不可约预测误差，有限测试集 MSE 会在其附近波动。

表 4 基础场景下的统计模型比较（5 个种子）

模型	测试 MSE	参数相对误差	非零数
Lasso（验证集选参）	0.348 ± 0.057	0.0738 ± 0.0124	77.0 ± 20.7
最小范数最小二乘	16.212 ± 1.286	0.8449 ± 0.0164	1000.0 ± 0.0
仅截距模型	22.662 ± 1.332	1.0000 ± 0.0000	0.0 ± 0.0

表4加入最小范数最小二乘和仅预测训练响应均值的模型作统计基线。最小二乘通过 SVD 求最小范数解，且同样只使用训练数据；它不是另一种 Lasso 求解器。本次稀疏高维设定下，Lasso 的测试误差低于这两项基线，体现了稀疏先验的作用。此比较没有包含调参后的岭回归，因此不能扩展为“Lasso 优于所有正则化方法”。

在图3对应的单次实验中，模型选择 63 个变量，其中真阳性 20 个、假阳性 43 个。模型能够识别真实活跃变量的主要幅度与符号，但还保留了小幅度的无关系数。验证集 MSE 选择的目标是预测，而不是支持集完全恢复；较小的多余系数可能只带来有限的预测影响。所以“检出了真实变量”与“只检出真实变量”必须分开判断，不能仅凭召回率高就认定精确恢复成功。

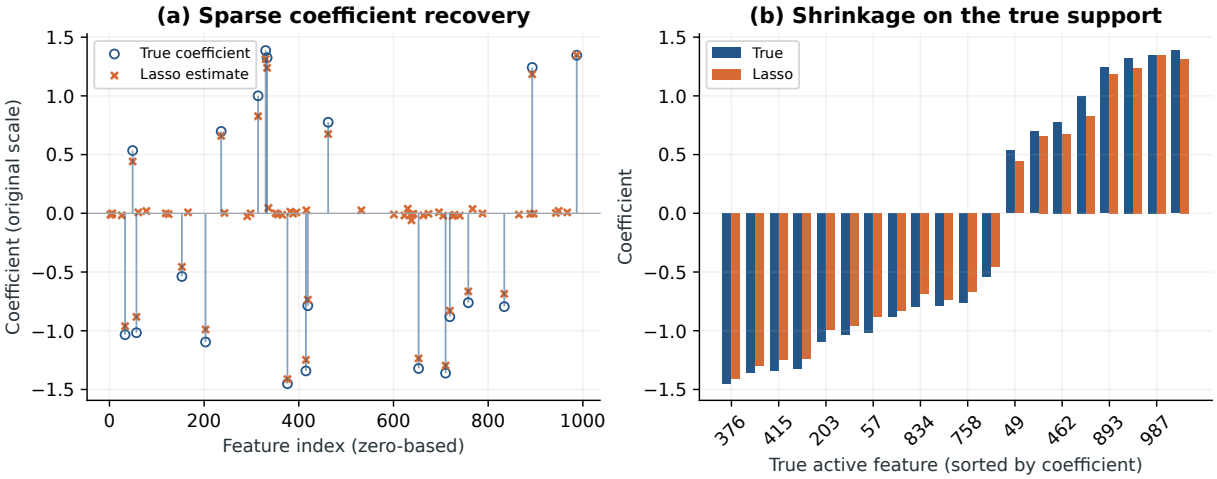


图 3 基础场景、种子 20261031、验证集所选模型的参数恢复。左图展示全部特征坐标中的真实和估计非零系数，右图按真实系数大小排列 20 个真实活跃变量。

5.4 正则化参数的影响

表 5 基础场景的正则化参数影响

$\lambda/\lambda_{\max}$	测试 MSE	参数误差	非零数	精确率	召回率
0.001	0.508 ± 0.091	0.1134 ± 0.0108	288.6 ± 2.6	0.069	1.000
0.003	0.473 ± 0.079	0.1061 ± 0.0096	270.2 ± 7.7	0.074	1.000
0.01	0.392 ± 0.061	0.0869 ± 0.0091	198.8 ± 19.7	0.101	1.000
0.03	0.348 ± 0.057	0.0738 ± 0.0124	77.0 ± 20.7	0.274	1.000
0.1	0.914 ± 0.251	0.1728 ± 0.0308	21.0 ± 1.0	0.954	1.000
0.3	5.947 ± 1.575	0.5017 ± 0.0677	18.2 ± 2.0	1.000	0.910
1	22.662 ± 1.332	1.0000 ± 0.0000	0.0 ± 0.0	0.000	0.000

前 3 项统计量为均值与样本标准差；精确率和召回率列仅列均值。

图4和表5展示三种区域。正则化很弱时，模型保留较多变量，部分噪声也进入估计；适中惩罚在本实验中得到较低预测误差；惩罚很强时，收缩偏差增大，真实变量可能被遗漏。当比例达到 1，数值结果给出零系数模型，与式(4)一致。这里的零系数模型仍通过训练响应均值给出常数预测。本次网格上模型大小总体随惩罚增大而减少，但一般 Lasso 路径中的单个变量可能进入后退出，不能把有限网格结果理解为任意数据下支持集必然严格嵌套的定理。

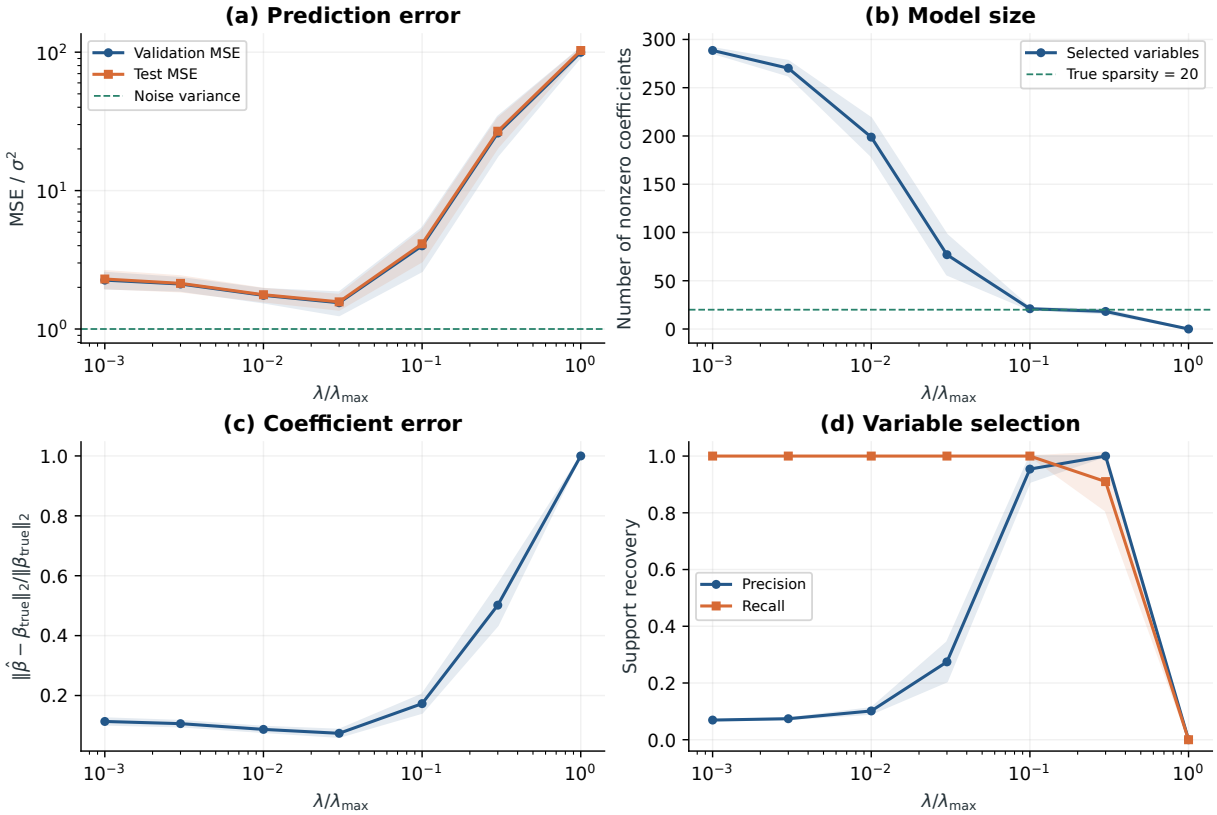


图 4 基础场景的正则化实验；折线为 5 个种子均值，阴影为一个样本标准差。测试误差曲线用于描述预先指定的参数网格，实际选参依据为各自验证集误差。

5.5 样本量、噪声与特征相关性

表 6 验证集选参后的单因素实验（每行 5 个种子）

场景	参数相对误差	测试 MSE	非零数	支持集 F1
基础场景	0.0738 ± 0.0124	0.348 ± 0.057	77.0 ± 20.7	0.427 ± 0.086
$n = 150$	0.1291 ± 0.0185	0.602 ± 0.126	103.4 ± 17.1	0.329 ± 0.045
$n = 600$	0.0509 ± 0.0062	0.278 ± 0.033	73.8 ± 70.9	0.556 ± 0.221
$\delta = 0.05$	0.0368 ± 0.0056	0.087 ± 0.014	124.8 ± 16.1	0.279 ± 0.032
$\delta = 0.3$	0.2293 ± 0.0392	3.217 ± 0.548	88.0 ± 58.0	0.435 ± 0.157
$\rho = 0.5$	0.0775 ± 0.0117	0.349 ± 0.064	94.4 ± 49.4	0.390 ± 0.119
$\rho = 0.9$	0.1257 ± 0.0168	0.356 ± 0.066	117.8 ± 16.1	0.294 ± 0.035

基础场景为 $n = 300$，$\rho = 0$，$\delta = 0.1$；每行只改变标出的一个因素。

样本量从 150 增至 600 时，参数相对误差的均值从 0.1291 降至 0.0509，测试 MSE 的均值从 0.6023 降至 0.2782。更多观测改善了本次问题中的参数辨识和泛化，但支持集 F1 仍受验证集选参目标影响，不应预设其会随样本量严格单调变化。

噪声比例从 0.05 增至 0.3 时，参数相对误差均值从 0.0368 增至 0.2293。不同噪声设定的绝对 MSE 同时包含不可约噪声的变化；因此还保存了以 σ^2 归一化的预测指标，避免将所有 MSE 增长都归因于求解算法。低噪声组的参数误差更小，但其支持集 F1 反而低于基础场景。这与验证集选出的更弱惩罚及更多小幅假阳性有关，不能解释为降低噪声本身不利于变量识别。

将相关系数从 0 增至 0.9 后，参数相对误差均值由 0.0738 变为 0.1257。强相关使若干特征具

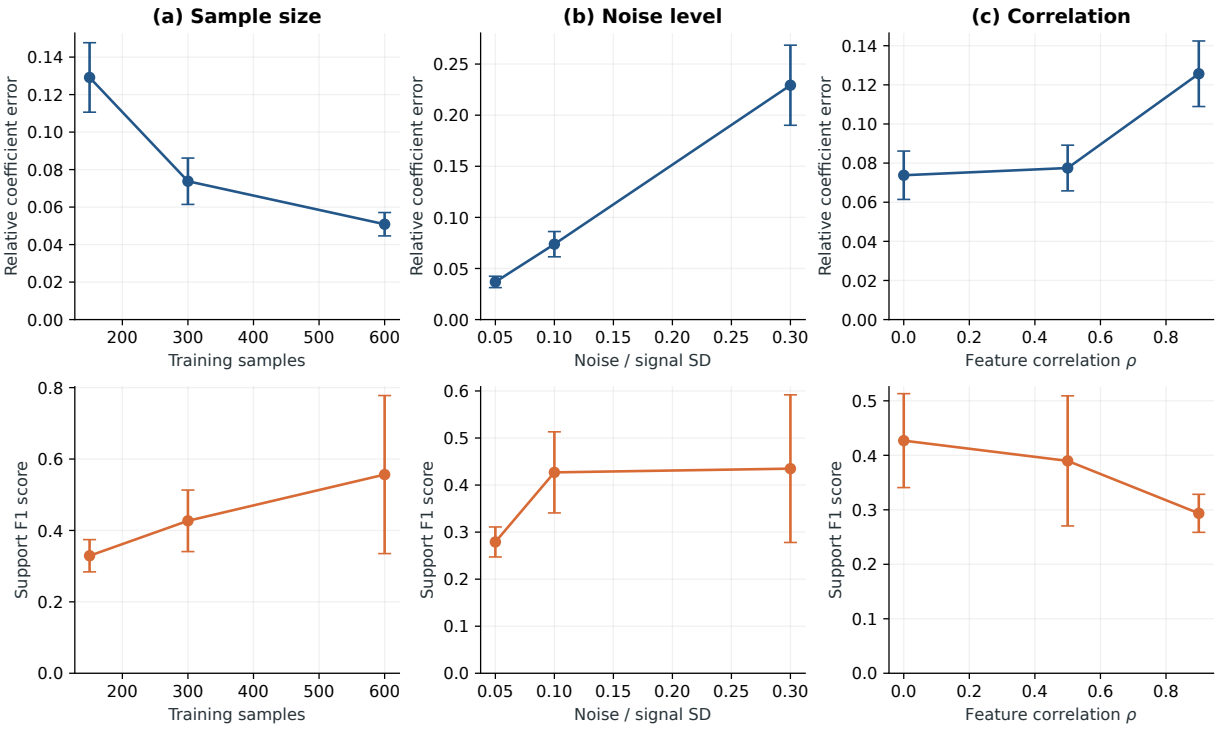


图 5 三个单因素实验。每个数据集均由独立验证集从相同候选网格选参；误差棒为 5 个种子的样本标准差。第一行衡量参数恢复，第二行衡量支持集恢复。

有相似解释能力，增加了准确区分系数与支持集的难度。与此同时，两组平均测试 MSE 接近，体现了相关变量之间可能用不同系数组合产生相近预测。表中反映的是“给定网格、验证集选择和稀疏信号分布”的联合结果，不能把它全部归结为优化误差，因为这些求解均已经达到同一最优性准则。仅有 5 个随机种子足以呈现实验现象，但不足以据此作广泛的统计显著性声明。

6 结论与局限

本研究完成了 Lasso 的建模、近端更新推导、ISTA/FISTA 独立实现与实际数值验证。核心结果可以归纳为以下几点：

1. ℓ_1 正则项的近端算子具有软阈值闭式解，使每轮迭代仅需矩阵–向量乘法和逐坐标阈值运算。固定步长 $1/L$ 下，ISTA 在本研究中稳定达到统一精度；与独立坐标下降解的目标值相符。
2. FISTA 在本次两组算法基准中减少了平均迭代数；具体时间收益受数据相关性、动量振荡、证书精度和实现开销影响。理论的 $O(1/k^2)$ 目标误差界不等于逐步单调下降，也不等于任意停止准则下的固定倍数加速。
3. 正则化控制预测与稀疏性的权衡。验证集选出的模型能够较好预测，却仍存在假阳性变量；优化精确、预测良好、支持集精确恢复是三个不同层次的结论。
4. 增加样本量在本次设定下改善了参数恢复，而高噪声和强相关增加了恢复难度。采用训练集预处理、独立验证集选参和独立测试评价，能避免将信息泄漏误认为模型性能提升。

本文的局限包括：使用合成线性高斯数据，不能直接证明对真实业务场景的适用性；候选 λ 网格较粗，且采用一次验证划分；仅进行 5 次随机重复；未研究稀疏矩阵、大规模分布式计算、自适应重启、回溯步长或非高斯噪声。后续可加入真实数据、交叉验证及更密的参数网格，并根据实际任务分别设计预测评价与变量筛选评价。

A 文件组织与复现说明

表 7 主要配套文件

文件	内容
`lasso.py`	软阈值、谱常数、ISTA/FISTA 和最优性证书。
`data.py`	随机问题生成、训练集预处理和统计指标。
`experiment_config.json`	预先固定的随机种子、网格和实验场景。
`run_experiments.py`	完整实验、计时及 CSV/NPZ 记录。
`make_figures.py`	从原始结果生成 5 组图表和汇总 CSV。
`verify_results.py`	核验结果完整性、最优性、选参和源文件哈希。
`build_report.py`	从结果生成数值表、PDF 及可编辑 Word 报告。
`tests/test_lasso.py`	6 项数学与实现正确性检查。
`results/`	原始指标、迭代轨迹、参考检查、环境版本和基础问题快照。
`figures/`	适合排版的 PDF 矢量图及 PNG 图片。
`report/lasso_report.tex`	本报告的 LaTeX 源文件。

在安装好 Python 依赖后，于项目根目录运行：

```
python -m unittest discover -s tests -v
python run_experiments.py
python verify_results.py
python make_figures.py
python build_report.py
```

完整实验本次实际耗时约 72.5 秒，不包含环境安装、绘图和文档编译；不同硬件耗时会变化。PDF 重新编译需要含 CTeX 的 XeLaTeX 环境；Word 导出需要配套的 Pandoc 依赖。若仅需复核结果，可以直接读取 `results/` 下的 CSV，无须重新运行实验。模型数值由固定种子和版本信息复现，运行时间不会逐位相同。详细环境安装、Apple Silicon 后端说明和文件使用方式见根目录的 `README.txt`。

参考文献

[1] Tibshirani R. Regression Shrinkage and Selection via the Lasso. Journal of the Royal Statistical Society: Series B, 1996, 58(1): 267–288. doi:10.1111/j.2517-6161.1996.tb02080.x.

[2] Daubechies I, Defrise M, De Mol C. An iterative thresholding algorithm for linear inverse problems with a sparsity constraint. arXiv:math/0307152, 2003. https://arxiv.org/abs/math/0307152.

[3] Beck A, Teboulle M. A Fast Iterative Shrinkage-Thresholding Algorithm for Linear Inverse Problems. SIAM Journal on Imaging Sciences, 2009, 2(1): 183–202. doi:10.1137/080716542.

[4] scikit-learn developers. Lasso: scikit-learn 1.6.1 documentation. https://scikit-learn.org/1.6/modules/generated/sklearn.linear_model.Lasso.html. 访问日期：2026-10-31。